EP2

Cálculo do Conjunto de Mandelbrot em Paralelo com OMPI e CUDA

Nesse EP temos apenas quatro membros pois um trancou a materia:

Nome	NUSP
Daniel Hotta	9922700
Matheus Laurentys	9793714
Pedro Gigeck	10737136
Rafael Gonçalves	9009600

Configuração do Ambiente

O ambiente será herdado do EP1

In [2]:

```
  Updating registry at `~/.julia/registries/General`
  Updating git-repo `https://github.com/JuliaRegistries/General.git`
    Fetching: [========================================>]  99.9 %    Fetching: [==
========================================>]  100.0 % Resolving package versions...
 Installed ZeroMQ_jll ── v4.3.2+4
 Installed MbedTLS_jll ─ v2.16.6+0
 Installed Parsers ──── v1.0.6
 Installed ZMQ ──────── v1.2.1
  Updating `~/.julia/environments/v1.3/Project.toml`
 [no changes]
  Updating `~/.julia/environments/v1.3/Manifest.toml`
 [c8ffd9c3] ↑ MbedTLS_jll v2.16.0+2 ⇒ v2.16.6+0
  [69de0a69] ↑ Parsers v1.0.2 ⇒ v1.0.6
  [c2297ded] ↑ ZMQ v1.2.0 ⇒ v1.2.1
  [8f1865be] ↑ ZeroMQ_jll v4.3.2+2 ⇒ v4.3.2+4
```

In [3]:

```
    Status `~/.julia/environments/v1.3/Project.toml`
  [7073ff75] IJulia v1.21.2
```

Sobre as Implementações

As implementações com pthreads, OMP e sequencial foram mantidas iguais ao EP1. Estão, respectivamente, em `mandelbrot_pth.c` , `mandelbrot_omp.c` e `mandelbrot_seq.c` .

A implementação com OMPI está em `mandelbrot_ompi.c` .

A implementação com CUDA está em `mandelbrot_cuda.cu` .

A implementação bônus MPI + OMP está em `mandelbrot_ompi_omp.c`

Para compilar todas as implementações, basta rodar o Makefile.

In [3]:

```
make: Nothing to be done for 'all'.
```

Podemos rodar qualquer uma das implementações para observar as imagens. Os arquivos executáveis estarão no diretório `bin`

In [ ]:

Na versão OMPI, o número de tasks é passado como parâmetro pelo mpirun, se não for passado, o mpirun definirá um valor default.

Na versão CUDA, possibilitamos a execução com grids e blocos uni e bidimensionais.

Para executar com uma dimensão, passe 8 argumentos na linha de comando, sendo os dois últimos os números de blocos e threads por bloco.

Para rodar com grids e blocos bidimensionais, passe 10 argumentos na linha de comando, sendo os 4 últimos as dimensões (x, y) do grid e blocos.

Na versão OMPI + OMP, o número de threads por task é o último argumento na linha de comando. Se não for passado, o OMP definirá como defaul uma thread por core.

De qualquer forma, as instruções sobre os argumentos da linha de comando são disparadas no console, caso não esteja compatível.

Determinação Experimental dos Parâmetros

Conforme especificado no enunciado, todas as medições foram feitas com 15 repetições, com o tamanho da imagem 4096 para a região Triple Spiral Valley.

Para medir os tempo de execução, usamos o script `run_measurements.sh` , com o comando `perf` , similar ao EP1.

Todos os resultados já estão na pasta results. O script leva algumas horas e não precisa ser rodado novamente.

In [ ]:

CUDA

Para a versão CUDA, os valores experimentados para o grid foram as seguintes combinações:

```
Blocos no grid = (1, 512, 1024, 2048)

Threads por bloco = (4, 8, 16, 32, 64, 128, 256, 512, 1024, 2048)
```

Podemos conferir os resultados nos gráficos gerados abaixo.

In [21]:

```
import Pkg
Pkg.add("Plots")
using DataFrames, Plots
using CSV

# DataFrame to concat all data to write in csv
df_csv = DataFrame()
```

```
# ---------- Getting CUDA results ----------

# GPU grid dimensions
cuda_blocks = [1, 512, 1024, 2048]
cuda_threads = [2 ^ x for x in 2:11]

# Get the time values from the log file and saves in a string
function get_log_string(implementation, arg)
    out = Pipe()
    cmd = pipeline(`grep '.seconds time elapsed.' results/$implementation/triple_spir
          pipeline(`awk '{print $1}'`; stdout=out))

    run(cmd)
    close(out.in)
    s = read(out, String)
    return s
end

# Get the percent values of the error from the log file and saves in a string
function get_log_deviation(implementation, arg)
    out = Pipe()
    cmd = pipeline(`grep '.seconds time elapsed.' results/$implementation/triple_spir
          pipeline(`awk '{print $(NF - 1)}'`; stdout=out))

    run(cmd)
    close(out.in)
    s = read(out, String)
    return s
end

# Create a dataframe with values from the log files for all grid sizes
function get_dataframe()
    df = DataFrame()
    sz = []
    times = []
    error = []
    for bl in cuda_blocks
        for th in cuda_threads
            dim = string(bl, "_", th)
            s = get_log_string("cuda", dim)
            d = get_log_deviation("cuda", dim)

            t = parse(Float64, s)
            dv = parse(Float64, chop(d, tail = 2))
            dv = t*dv/100

            push!(times, t)
            push!(error, dv)
            push!(sz, bl * th)
        end
    end

    df[!, "sz"] = sz
    df[!, "times"] = times
    df[!, "dv"] = error
    df_csv[!, "cuda.sz"] = sz
    df_csv[!, "cuda.times"] = times
    df_csv[!, "cuda.DP"] = error
    return df
end

function plot_dataframe(df)
    xs = df.sz
    ys = df.times
```

```
    deviation = df.dv
    scatter(xs, ys, yerror = deviation, label = "", xscale = :log10, yscale = :log10,
            xlabel = "Total de Threads", ylabel = "Tempo (s)",
            title = "Tempo x Total de Threads\nImplementação CUDA\n")
end

function plot_heatmap(df)
    data = convert(Array{Float64,1},df.times)
    data = reshape(data, 4, 10)
    heatmap(string.(cuda_threads),
            string.(cuda_blocks),
            data, colorbar_title = "tempo (s)", color = :viridis,
            xlabel="número de threads", ylabel="número de blocos", clims = (0, 10),
            title="Tempo(s) x (Threads x Blocos)")
end

df = get_dataframe()
CSV.write("./results/csv_cuda.csv", df)
```

```
plot_dataframe(df)
```

```
  Resolving package versions...
   Updating `/mnt/c/Users/gigec/OneDrive/Área de Trabalho/Pedro/BCC/MAC0219 Parale
la/mac-0219/EP2/Project.toml`
 [no changes]
   Updating `/mnt/c/Users/gigec/OneDrive/Área de Trabalho/Pedro/BCC/MAC0219 Parale
la/mac-0219/EP2/Manifest.toml`
 [no changes]
```

Out[21]:

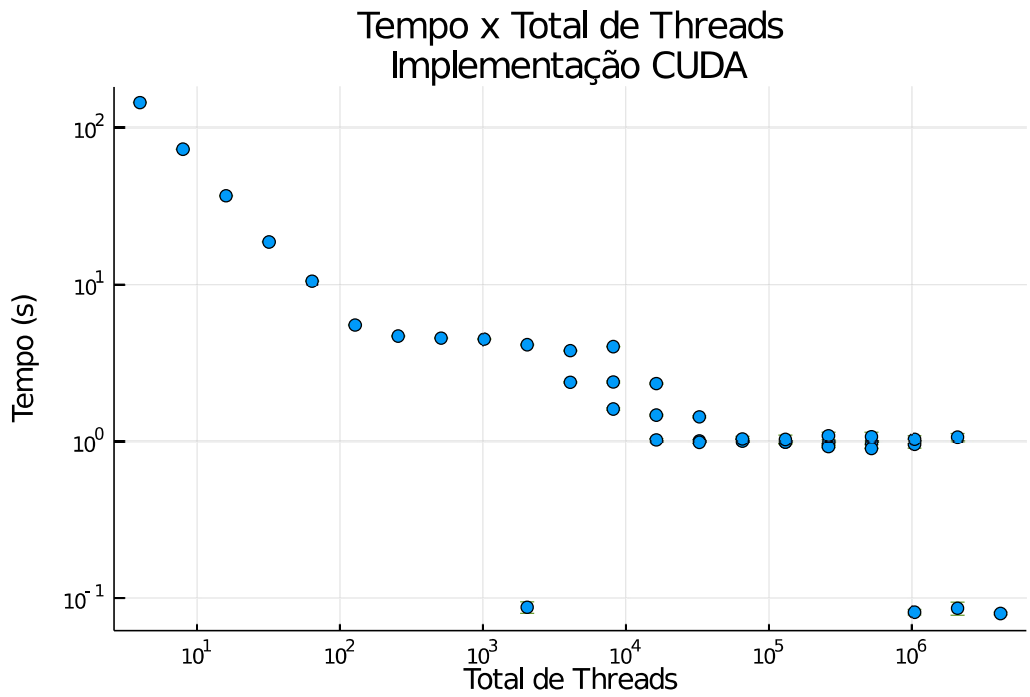

In [22]:

Out[22]:

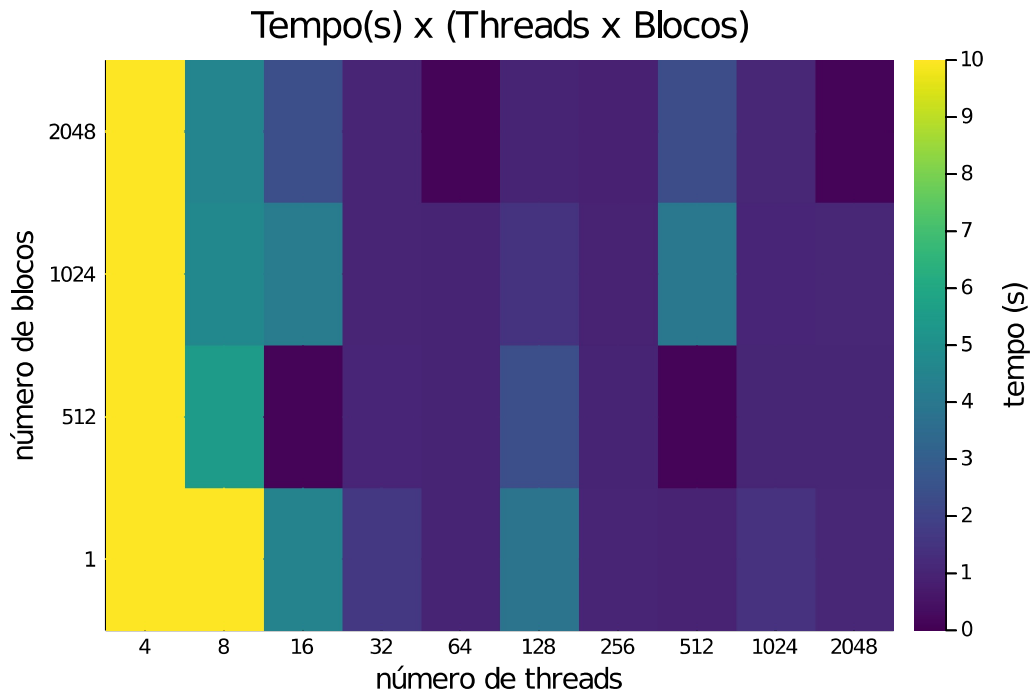

O primeiro ponto a ser notado é a estabilidade das execuções. No código, podemos conferir que o desvio padrão das medições está sendo mostrado, porém ele é menor que o ponto na representação gráfica. Nos experimentos, conferimos que o desvio padrão não passa de 1 segundo em nenhuma execução.

Outro resultado é que, em geral, o tempo de execução é inversamente proporcional ao número total de threads. Quanto mais threads, mais rápido. Observamos isso na tendência de queda do primeiro gráfico (que está em escala logarítmica). Com outras implementações paralelas, observávamos um número de threads que minimizava o tempo de execução e quando executado com mais threads, o tempo aumentava.

A principal explicação para esse fenômeno está no hardware. O potencial de computação paralela de uma GPU, que pode executar milhares de threads simultaneamente, não é comparável com o potencial de uma CPU com 4 ou 8 núcleos.

Além disso, sabemos que a distribuição dos blocos nos grids não influenciam bruscamente no tempo de execução. O que importa é o número total de blocos e o número de threads por bloco. No segundo gráfico, vemos que existem configarações que beneficiam o desempenho. Como o caso de 512 blocos com 16 threads, que teve um desempenho quase 10 vezes melhor que outras combinações com o mesmo númeor total de threads.

Com isso, concluímos que os melhores parâmetros para execução do experimento são aqueles que maximizam o total de threads, que é capacidade máxima da GPU, no nosso caso, **2048 blocos com 2048 threads**.

OMPI

Para a implementação com OMPI, usamos as quantidades de processos 4, 8, 16, 32 e 64, conforme sugerido no enunciado.

In [23]:

```
# ---------- Getting OMPI results ----------

# Number of tasks OMPI
ompi_tasks = [2 ^ x for x in 2:6]
```

```
# Create a dataframe with values from the log files
function get_dataframe()
    df = DataFrame()
    sz = []
    times = []
    error = []
    for i in ompi_tasks
        s = get_log_string("ompi", i)
        d = get_log_deviation("ompi", i)
        s = replace(s, ','=>'.')
        d = replace(d, ','=>'.')
        t  = parse(Float64, s)
        dv = parse(Float64, chop(d, tail = 2))
        dv = t * dv / 100

        push!(times, t)
        push!(error, dv)
        push!(sz, string(i))
    end

    df[!, "sz"] = sz
    df[!, "times"] = times
    df[!, "dv"] = error
    return df
end

function plot_dataframe(df)
    xs = df.sz
    ys = df.times
    deviation = df.dv
    plot(xs, ys, seriestype = :scatter, yerror = deviation, label = "", xlabel = "Núm
         ylabel = "Tempo (s)", title = "Tempo x Total de Tasks\n")
end

# Plot (time x total_tasks) graph
df = get_dataframe()
CSV.write("./results/csv_ompi.csv", df)
```

Out[23]:

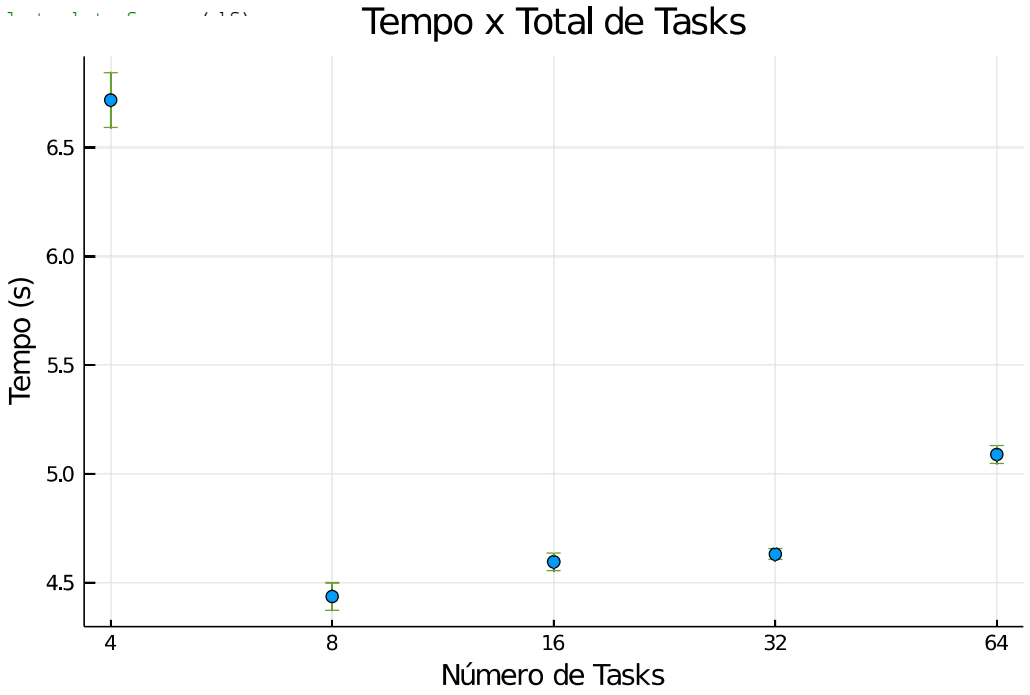

Observa-se que temos o menor tempo de execução para o ponto com 8 processos sendo executados, sendo que esse tempo aumenta conforme acrescentamos mais processos ao calculo da imagem.

Além disso, temos um ponto estranho a ser considerado, sendo ele referente ao calculo realizado usando 4 processos, que apresenta um tempo de execução significativamente maior que outros pontos observados. A diminuição de 4 para 8 processos é natural, já que paralelizamos mais o trabalho. O aumento do tempo de execução a partir de 8 processos pode ser explicado pela complexidade na troca de mensagens entre os processos, e no fato de estarmos executando em uma máquina com 8 processadores.

Porém, devemos considerar que o MPI é uma ferramenta para execução distribuída dos processos e não na mesma máquina, por isso podemos observar irregularidades como essa.

OMPI + OMP

Para a implementação bônus de OMPI com OMP, testamos com o mesmo número de processos que a OMP e o mesmo número de threads que usado no EP1 para OMP.

```
número de processos = (4, 8, 16, 32, 64)
```

```
número de threads = (1, 2, 4, 8, 16, 32, 64, 128, 256, 512, 1024, 2048)
```

Embora já tenhamos resultados isolados sobre as duas técnicas, vamos conferir se a combinação de ambas mantém o desempenho dos parâmetros conforme esperado:

In [27]:
```
# ---------- Getting OMPI + OMP results ----------

ompi_tasks  = [2 ^ x for x in 2:6]
omp_threads = [2 ^ x for x in 1:5]

# Create a dataframe with values from the log
function get_dataframe()
    df = DataFrame()
    sz = []
    times = []
    error = []
    for i in ompi_tasks
        for th in omp_threads
            dim = string(i, "_", th)
            s = get_log_string("ompi_omp", dim)
            d = get_log_deviation("ompi_omp", dim)

            s = replace(s, ','=>'.')
            d = replace(d, ','=>'.')
            t  = parse(Float64, s)
            dv = parse(Float64, chop(d, tail = 2))
            dv = t * dv / 100

            push!(sz, i*th)
            push!(times, t)
            push!(error, dv)
        end
    end

    df[!, "sz"] = sz
    df[!, "times"] = times
    df[!, "dv"] = error
    return df
end

function plot_dataframe(df)
```

```
    xs = df.sz
    ys = df.times
    deviation = df.dv
    plot(xs, ys, seriestype = :scatter, yerror = deviation, label = "",
         xlabel = "Número de threads em todos os processos",
         ylabel = "Tempo (s)", title = "Tempo x Total de Processos x Threads\n")
end

function plot_heatmap(df)
    data = convert(Array{Float64,1}, df.times)
    data = reshape(data, 5, 5)
    heatmap(string.(omp_threads),
            string.(ompi_tasks),
            data, colorbar_title = "tempo (s)", color = :viridis,
            xlabel="número de threads", ylabel="número de processos",
            title="Tempo(s) x (Threads x Processos)")
end


# Plot (time x total_tasks) graph
df = get_dataframe()
CSV.write("csv_ompi_omp.csv", df)
```

Out[27]:

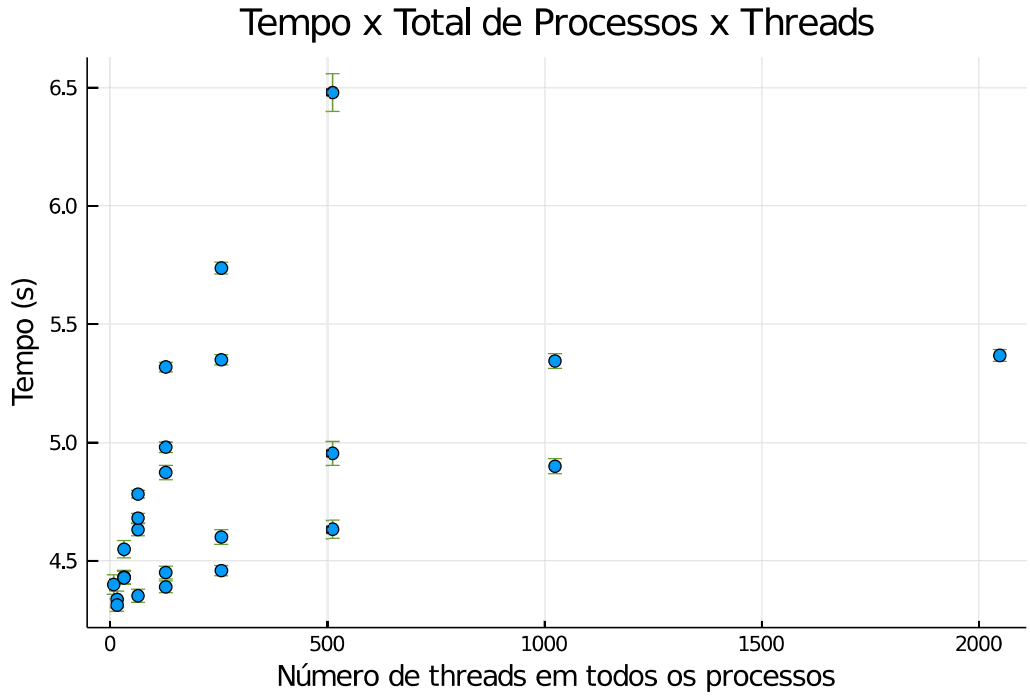

In [28]:

Out[28]:

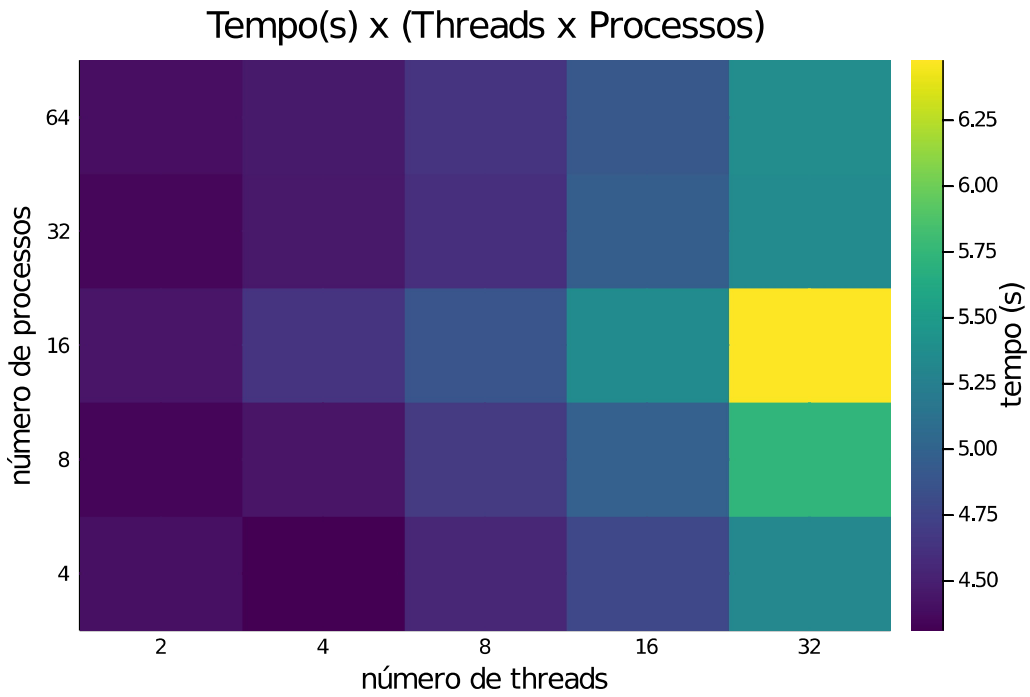

Para nossa surpresa, a configuração que obteve melhor resultado foi com 4 processos e 4 threads.

A possível causa para isso é a complexidade de paralelizar demais uma tarefa em apenas uma máquina. Provavelmente, ao executar em diversos dispositivos as execuções com mais processos levariam vantagem.

Isso também reflete no aumento do tempo com o aumento do número de threads. Vemos no primeiro gráfico que as execuções com menos threads tendem a levar vantagem, pois paralelizam o trabalho em uma quantidade compatível com o potencial do máquina.

Comparando Implementações

Relembrando quais foram os melhores parâmetros obtidos para cada implementação:

Implementação	Threads	Outro Parâmetro
Pthreads	32 threads	
OMP	32 threads	
CUDA	2048 threads	2048 blocos
OMPI		8 processos
OMPI + OMP	4 threads	4 processos

Comparando as implementações com esses parâmetros:

(os dados de pthreads e OMP foram copiados dos results do EP1)

In [30]:
```
# ---------- Plotting graph for all versions ----------

# Each version with best parameters
implementations = [["seq", ""],
                   ["pthreads", "32"],
                   ["omp", "32"],
                   ["ompi", "8"],
```

```
                    ["cuda", "2048_2048"],
                    ["ompi_omp", "4_4"]]

function get_comparison_dataframe()
    df = DataFrame()
    names = []
    times = []
    error = []
    for i in implementations
        s = get_log_string(i[1], i[2])
        d = get_log_deviation(i[1], i[2])
        s = replace(s, ','=>'.')
        d = replace(d, ','=>'.')

        t = parse(Float64, s)
        dv = parse(Float64, chop(d, tail = 2))
        dv = t*dv/100

        push!(times, t)
        push!(error, dv)
        push!(names, i[1])
    end

    df[!, "names"] = names
    df[!, "times"] = times
    df[!, "dv"] = error

    return df
end

function plot_comparison(df)
    bar(df.names, df.times, yerror = df.dv, label = "",
        ylabel = "tempo (s)", title = "Comparação entre Implementações")
end

df = get_comparison_dataframe()
```

Out[30]:

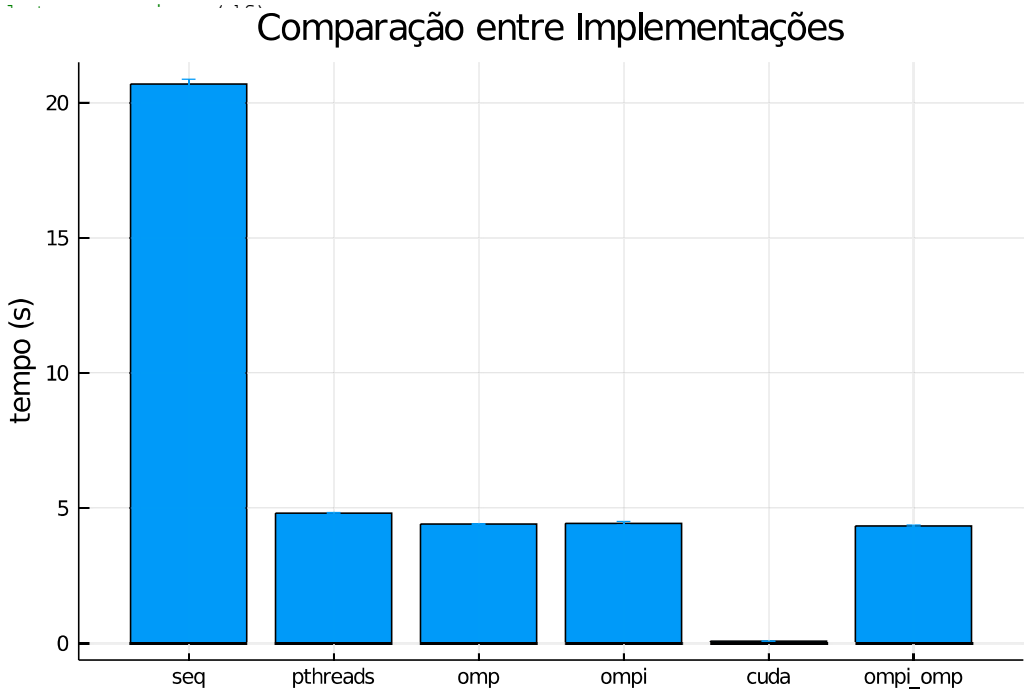

Com esse gráfico final, dois fenômenos principais chamam a atenção: a eficiência extraordinária de CUDA e a vantagem geral de implementações paralelas.

A eficiência de cuda, como já observado, se deve a arquitetura do hardware da GPU, que tem um potêncial de paralelização muito maior que a CPU. E, como a tarefa de calcular o conjunto de Mandelbrot é trivialmente paralelizável, essa implementação leva muita vantagem sobre as outras.

O segundo ponto é a comparação entre a implementação sequêncial e as paralelizadas. Independente da técnica escolhida, diminuímos mais de 4x o tempo de execução. Isso é, com apenas algumas mudanças no código, quadruplicamos o desempenho da nossa aplicação!

Assim, devemos sempre focar em aproveitar o máximo do hardware que temos disponível ao mesmo tempo, tanto os vários núcleos de processamento quanto os dispositivos mais específicos como a GPU.